

Operationalizing Historical Questions

Datafying the Library of Congress
Vietnam Collections



Cindy A. Nguyen, History
University of California, Berkeley

Introduction

Ph.D. Candidate in Vietnamese history

Fields in Colonial Knowledge, History of
Science & Classification, Digital
Humanities

...interdisciplinary journey of
cross-pollination: from source criticism to
experimental design, open-access and
diversifying the language of the internet

cindyanguyen.com

@cindyanguyen

Builders & Users: Constructing the Vietnamese Library (1887-1986)



What is the history of Vietnamese 'public' libraries during the political regime changes of the 20th century?

How do libraries demonstrate the relationship among:

- the state (colonial, post-colonial)
- the public (reading preferences)
- education, language, and literacy
- ideas about modernity, access to knowledge, civil society



Fieldwork: Archives & Research collaborations in Vietnam

University of California, Berkeley

Spring 2016- Information Science 290

Final Project

A Humanist does Data Science: Deconstructing Libraries

Cindy A. Nguyen, History

Jordan Shedlock, School of Information



A HUMANIST DOES DATA SCIENCE: 'DECONSTRUCTING' LIBRARIES PROJECT



Library of Congress Main Reading Room

Spring of 2016 I enrolled in my first ever graduate level data science course at the School of Information at UC Berkeley. The course 'Deconstructing Data Science' investigated quantitative

ABOUT ME



Hi, I am Cindy Nguyen. I received my M.A. at MSU, and am currently a Ph.D. Candidate in Vietnamese History at UC Berkeley.

My interests include digital humanities, Southeast Asia, history of the book, materiality, and classification. My dissertation examines a cultural history of colonial and postcolonial Vietnamese libraries.

Website

cindyanguyen.com

Github

<https://github.com/cindyanguyen/deconstructing-libraries>

Blog post

<https://cindyanguyen.com/2016/12/02/a-humanist-does-data-science-deconstructing-libraries-project/>

1. Operationalizing research questions
2. Tools to clean, read, analyze data
3. Concluding lessons

1. Operationalizing research questions

How to ask questions and how to answer them

- Translating research questions into operationalizable tasks
 - What evidence do I have to support my research claim? How do I argue this?
- Critical inquiry into data: its production and limitations
- What question does this actually answer?

MOTIVATIONS & RESEARCH QUESTION


Relationship between politics and culture through the lens of libraries

Nguyen's dissertation examines the cultural and political history of libraries in Vietnam from 1885 to 1986. How does the library develop as an institution of knowledge in Vietnam? In what ways do Vietnamese libraries transform through political regime changes? How do libraries express colonial and post-colonial state power as well as subvert it?

RESEARCH QUESTION

- | | |
|-----------|---|
| 1885-1945 | French Colonialism |
| 1946-1954 | First Indochina War |
| 1954-1975 | Second Indochina War/ Vietnam War |
| 1975-1979 | Vietnam-Cambodia War,
Sino-Vietnamese Conflict |
| 1986 | Renovation Neo-Liberal Reforms & |

Rapprochement between US & Vietnam



Mobile library, 1936 Saigon

Iterating between Research Question & Data

→ What type of data gestures at my research topic? (libraries, government, readership, libraries development, collections)

- Ideal data source?

→ What more refined research question can emerge from my data source? (curation, control, censorship, ideology, language, literacy)

- Example research question?

Finding Data

Humanistic data: difficult to obtain, uneven, unformatted, not easily machine readable

Not 'data of convenience' - well structured in the English language

→ justifiably 'interesting' and significant

VIETNAMESE HOLDINGS in the Library of Congress

A Bibliography

Compiled by A. Kohar Rony
Southern Asia Section, Asian Division

LIBRARY OF CONGRESS WASHINGTON 1982

Digitized by Google

Original from
UNIVERSITY OF MICHIGAN

MONOGRAPHS

A

- 1
An Khê. Bông lúa sa-mơ; truyện dài. [Saigon] Miền Nam, 1968.
510 p.
PL4378.9.A45B6
- 2
An Khê. Chân trời nào cho em; tiểu thuyết tình cảm xã hội. [Saigon] Đồng Nai, 1971.
276 p.
PL4378.9.A45C5
- 3
An Khê. Mối tình đầu; tiểu-thuyết tình-cam xã-hội. [Saigon] Miền Nam [1965]
479 p.
PL4378.9.A45M6
- 4
Anh Đảo. Việt Nga hội thoại. [Hà-nội] Sông Lô, 1956.
118 p.
Errata slip inserted.
PG2121.A54
- 5
Anh Đức. Bức thư Cà-mau; truyện ngắn, bút ký. [In lần thứ 2] Hà-nội, Văn Học, 1966.
135 p.
"Giới thiệu chính thức văn học Nguyễn Đình Chiểu."
PL4378.9.A5B8 1966
- 6
Anh Đức. Đứa con của đất: tiểu thuyết. [s.l.] Văn Học Giải Phóng, 1975.
487 p.
PL4378.9.A5D8
- 7
Anh Đức. Một truyện chép ở bệnh viện; truyện. In lần thứ 2. [Hà-nội] Văn Học, 1963.
151 p.
PL4378.9.A5M6 1963
- 8
Anh Đức. Tháng Mỵ. Bìa và minh họa của Văn Đa. Hà-nội, Kim Đồng, 1966.
31 p. illus.
"Trích trong Bức thư Cà-mau."
PL4378.9.A5T48
- 9
Anh Thơ. Mùa xuân, màu xanh: thơ 1967-1973. Hà-nội, Văn Học, 1974.
109 p.
PL4378.9.A55M8
- 10
Anh Thơ. Theo cánh chim câu; thơ, 1945-1960. [Hà-nội] Văn Học, 1960.
105 p.
PL4378.9.A55T5
- 11
Anh Thơ. Những bài hát mới viết trên tóc me. Saigon [Phủ Sa Nhạc Tuyền], 1967.
42 p. illus.
Unacc. melodies.
M1824.V5A5

B

- 12
Bà Dưng. Nàng sông Lam: truyện ký. [Hà-nội] Phụ Nữ, 1974.
117 p.
PL4378.9.B2N3
- 13
Ba Hồng và Phạm Hồng. Vòng quanh Sài-gòn: ký sự. [s.l.] Văn Nghệ Giải Phóng, 1975.
124 p.
PL4378.9.B24V6

1

Digitized by Google

Original from
UNIVERSITY OF MICHIGAN

- Author
- Title
- Publication City
- Publisher
- Publishing date
- Number of pages
- Library of Congress classification number

Why is this data source significant?
What story could I tell?

2
An Khê. Chân trời nào cho em; tiểu thuyết tình cảm xã hội. [Saigon] Đồng Nai, 1971.
276 p.
PL4378.9.A45C5

3
An Khê. Mối tình đầu; tiểu-thuyết tình-cam xã-hội. [Saigon] Miền Nam [1965]
479 p.
PL4378.9.A45M6

4
Anh Đào. Việt Nga hội thoại. [Hà-nội] Sông Lô, 1956.
118 p.
Errata slip inserted.
PG2121.A54

5
Anh Đức. Bức thư Cà-mau; truyện ngắn, bút ký. [In lần thứ 2] Hà-nội, Văn Học, 1966.
135 p.
PL4378.9.A5B8 1966
"Giải thưởng chính thức văn học Nguyễn Đình Chiểu."

6
Anh Đức. Đứa con của đất; tiểu thuyết. [s.l.] Văn Học Giải Phóng, 1975.
487 p.
PL4378.9.A5D8

8
Anh Đức. Thăng My. Bìa và Hà-nội, Kim Đồng, 1966.
31 p. illus.
"Trích trong Bức thư Cà-mau"

9
Anh Thơ. Mùa xuân, màu Hà-nội, Văn Học, 1974.
109 p.

10
Anh Thơ. Theo cánh chim cá nê] Văn Học, 1960,
105 p.

Anh-Tuân Nguyễn Tuân Phái
ơ Nguyễn Tuân Phát

11
Anh Việt Thu. Những bài h
Saigon [Phủ Sa Nhạc Tuyền
42 p. illus.
Unacc. melodies.

- Author
- Title
- Publication City
- Publisher
- Publishing date
- Number of pages
- Library of Congress classification number

- Library curation
- History of publishing in Vietnam
- Circulation of knowledge on Vietnam

2
 An Khê. Chân trời nào cho em; tiểu thuyết tình cảm xã hội. [Saigon] Đồng Nai, 1971.
 276 p.
 PL4378.9.A45C5

3
 An Khê. Mối tình đầu; tiểu-thuyết tình-cảm xã-hội. [Saigon] Miền Nam [1965]
 479 p.
 PL4378.9.A45M6

4
 Anh Đào. Việt Nga hội thoại. [Hà-nội] Sông Lô, 1956.
 118 p.
 Errata slip inserted.
 PG2121.A54

5
 Anh Đức. Bức thư Cà-mau; truyện ngắn, bút ký. [In lần thứ 2] Hà-nội, Văn Học, 1966.
 135 p.
 "Giải thưởng chính thức văn học Nguyễn Đình Chiểu."
 PL4378.9.A5B8 1966

6
 Anh Đức. Đứa con của đất; tiểu thuyết. [s.l.] Văn Học Giải Phóng, 1975.
 487 p.
 PL4378.9.A5D8

8
 Anh Đức. Thăng My. Bìa và Hà-nội, Kim Đồng, 1966.
 31 p. illus.
 "Trích trong Bức thư Cà-mau"

9
 Anh Thơ. Mùa xuân, màu Hà-nội, Văn Học, 1974.
 109 p.

10
 Anh Thơ. Theo cánh chim cá nê] Văn Học, 1960,
 105 p.

Anh-Tuân Nguyễn Tuân Phái
 và Nguyễn Tuân Phát

11
 Anh Việt Thu. Những bài h
 Saigon [Phủ Sa Nhạc Tuyền
 42 p. illus.
 Unacc. melodies.

What it is and what it could be:

Data includes information on:

- The 1982 bibliography includes Vietnamese language materials the LOC collected up to June 1979.
- The 1987 bibliography includes Vietnamese language materials collected by the LOC from 1979 to 1985.
- Both retrospective works and new items published in post-war Socialist Republic of Vietnam
- Author
- Title
- Publication City
- Publisher
- Publishing Date
- Number of Pages
- Library of Congress Classification
- Language
- Monograph or Serial

Data could shed light on:

- A part of publishing history
 - North and South Vietnam (during the War)
 - Post-war Socialist Republic of Vietnam
 - Diasporic Vietnamese populations
- Topics and types of works published
- Library curation - logic of collection
- Knowledge access to Americans on the subject of 'Vietnam'

Assumptions - History of the book

'TITLE'

- What *information* does a work's title contain?

'PUBLICATION CITY'

- What does the publication city suggest?

Testable Hypotheses

1. Different publication locations will have different distribution of topics.
What are the topics/words most characteristic of a city?
 - a. H1: Hanoi will have more topics on Communism, war, revolution, army than Saigon.
 - b. H2: Saigon will have more topics on US ideas (modernity, democracy, anti-Communism)
 - c. H3: LOC collection will prefer Saigon (ally) materials over Hanoi.

2. Operationalized through
 - a. Distribution of collected works by Library of Congress Classification
 - b. Probability of words in a title by city
 - c. Topic Models

2. Tools to clean, read, analyze data

Data Cleaning

DATA

- Data cleaning and preparation:


- **Optical Character Recognition** (Abbyy Finereader): from PDF to text file
- **Regex**: extract author, title, year, publisher, location
- **Google Refine**: clean up data fields, resolve OCR errors and misspellings
- **vnTokenizer**: tokenize Vietnamese words cách mạng = cách-mạng [revolution]

13
35 năm chiến đấu và xây dựng. Hà Nội, Sự Thật, 1980.
DS556.8.A13 1980 Orien Viet
83-189533
426 p. illus., plates.
Includes bibliographical references.

14
Ba ngày lễ lớn năm 1980; để cương tuyến truyền. Hà
Nội, Quân Đội Nhân Dân, 1980.
DS559.912.B3 Orien Viet
81-203188
129 p.

13
35 năm chiến đấu và xây dựng. Hà Nội, Sự Thật, 1980.
DS556.8.A13 1980 Orien Viet
83- 189533
426 p. illus., plates.
Includes bibliographical references.

14
Ba ngày lễ lớn năm 1980; để cương tuyến truyền. Hà
Nội, Quân Đội Nhân Dân, 1980.
DS559.912.B3 Orien Viet
81- 203188
129 p.



35 years of war and building

3 major holidays in 1980; an outline of the stories of beloved uncle Hồ

35 năm chiến đấu và xây dựng
ba ngày lễ lớn năm 1980 ; để cương tuyến truyền
bác hồ kính yêu


Frequency counts

4417 Total records LOC 82, 87

2016 Hanoi


1139 Saigon

1252 Non-Hanoi or
Non-Saigon, Messy OCR/RegEx



Frequency counts


- LOC collected more books from Hanoi than Saigon.
- Even after the Vietnam War, LOC collecting regime interested in Hanoi politics and Communist ideology.
“Understanding American studies of Marx-Lenin”
1979, *“Beloved Uncle Ho”*
1970



Library of Congress Classification (LCC) Breakdown by City

- **Topics consistent across cities:**
- **PL:** Languages and Literature
- **DS:** Asian History

This suggests that the data reflect the LOC's **collection policies** first and foremost; **ideological distinctions/content** are not captured



What are the words most characteristic of a city?

1. Exploratory

- a. Naive Bayes (Probability of word in title conditioned on city)
- b. Topic models (learn patterns that suggest types of books from a city)

2. Prediction

- a. Naive Bayes (Can we predict an unknown city based on the words in a title?)

Naive Bayes

Probability of word in title conditioned on city; bigrams only, no stopwords

Red text: words that co-occur in top 21 results of Hanoi and Saigon

Φ , Y=Hanoi

cách_mạng	0.002979032196463354	<i>revolution</i>
truyện_ngắn	0.0019860214643089027	<i>short story</i>
nhân_dân	0.001871443302906466	<i>people</i>
minh_họa	0.0017950578619715081	<i>illustrate</i>
dân_tộc	0.001527708818699156	<i>nation</i>
truyện_ký	0.0014131306572967193	<i>memoir</i>
xây_dựng	0.0014131306572967193	<i>build</i>
anh_hùng	0.0012985524958942826	<i>hero</i>
công_tác	0.0012603597754268037	<i>activity</i>
nghiên_cứu	0.0011839743344918459	<i>research</i>
giới_thiệu	0.001145781614024367	<i>introduction</i>
nhiệm_vụ	0.0010693961730894091	<i>duty</i>
biên_soạn	0.0009930107321544513	<i>compile</i>
khoa_học	0.0009930107321544513	<i>science</i>
văn_học	0.0009930107321544513	<i>literature</i>
xã_hội	0.0009166252912194935	<i>society</i>
nông_nghiệp	0.0008784325707520146	<i>agriculture</i>
lịch_sử	0.0008020471298170569	<i>history</i>
nghệ_thuật	0.0008020471298170569	<i>art</i>
chú_thích	0.0008020471298170569	<i>note</i>
bổ_sung	0.0007256616888820991	<i>supplement</i>

Φ , Y=Saigon

truyện_dài	0.0048038917604135	<i>long story</i>
truyện_ngắn	0.0007297050775311645	<i>short story</i>
giáo_dục	0.0006688963210702341	<i>education</i>
cách_mạng	0.0005472788081483734	<i>revolution</i>
công_dân	0.000486470051687443	<i>citizen</i>
văn_hóa	0.000486470051687443	<i>culture</i>
văn_học	0.000486470051687443	<i>literature</i>
chú_thích	0.000486470051687443	<i>note</i>
chúng_ta	0.0004256612952265126	<i>we</i>
phật_giáo	0.0004256612952265126	<i>Buddhism</i>
giới_thiệu	0.00036485253876558226	<i>introduction</i>
cộng_hòa	0.00036485253876558226	<i>republic</i>
xã_hội	0.00036485253876558226	<i>society</i>
phiên_dịch	0.00036485253876558226	<i>translate</i>
quê_hương	0.00036485253876558226	<i>homeland</i>
con_người	0.0003040437823046519	<i>person</i>
hiện_đại	0.0003040437823046519	<i>modern</i>
giáo_sư	0.0003040437823046519	<i>professor</i>
khuôn_mặt	0.0003040437823046519	<i>face</i>
cuộc_đời	0.0003040437823046519	<i>lifetime</i>
lịch_sử	0.0003040437823046519	<i>history</i>

Naive Bayes

Probability of word in title conditioned on city; bigrams only, no stopwords

Highlighted blue: words of interest for comparison of results between Hanoi and Saigon

Φ , Y=Hanoi

cách_mạng	0.002979032196463354	revolution
truyện_ngắn	0.0019860214643089027	short story
nhân_dân	0.001871443302906466	people
minh_họa	0.0017950578619715081	<i>illustrate</i>
dân_tộc	0.001527708818699156	<i>nation</i>
truyện_ký	0.0014131306572967193	<i>memoir</i>
xây_dựng	0.0014131306572967193	build
anh_hùng	0.0012985524958942826	hero
công_tác	0.0012603597754268037	<i>activity</i>
nghiên_cứu	0.0011839743344918459	<i>research</i>
giới_thiệu	0.001145781614024367	<i>introduction</i>
nhiệm_vụ	0.0010693961730894091	<i>duty</i>
biên_soạn	0.0009930107321544513	<i>compile</i>
khoa_học	0.0009930107321544513	<i>science</i>
văn_học	0.0009930107321544513	literature
xã_hội	0.0009166252912194935	society
nông_nghiệp	0.0008784325707520146	<i>agriculture</i>
lịch_sử	0.0008020471298170569	<i>history</i>
nghệ_thuật	0.0008020471298170569	<i>art</i>
chú_thích	0.0008020471298170569	<i>note</i>
bổ_sung	0.0007256616888820991	<i>supplement</i>

Φ , Y=Saigon

truyện_dài	0.0048038917604135	<i>long story</i>
truyện_ngắn	0.0007297050775311645	short story
giáo_dục	0.0006688963210702341	<i>education</i>
cách_mạng	0.0005472788081483734	revolution
công_dân	0.000486470051687443	citizen
văn_hóa	0.000486470051687443	<i>culture</i>
văn_học	0.000486470051687443	literature
chú_thích	0.000486470051687443	<i>note</i>
chúng_ta	0.0004256612952265126	<i>we</i>
phật_giáo	0.0004256612952265126	Buddhism
giới_thiệu	0.00036485253876558226	<i>introduction</i>
cộng_hòa	0.00036485253876558226	<i>republic</i>
xã_hội	0.00036485253876558226	society
phiên_dịch	0.00036485253876558226	<i>translate</i>
quê_hương	0.00036485253876558226	homeland
con_người	0.0003040437823046519	<i>person</i>
hiện_đại	0.0003040437823046519	modern
giáo_sư	0.0003040437823046519	<i>professor</i>
khuôn_mặt	0.0003040437823046519	<i>face</i>
cuộc_đời	0.0003040437823046519	<i>lifetime</i>
lịch_sử	0.0003040437823046519	<i>history</i>

Naive Bayes to Predict Unknown City

$P(X = \text{"Anh hùng lực lượng vũ trang nhân dân"} | Y = \text{Hanoi}) = 1.5648340863728223$

$P(X = \text{"Anh hùng lực lượng vũ trang nhân dân"} | Y = \text{Saigon}) = 0.0002585442251010566$

True value =

⁵
**Anh hùng lực lượng vũ trang nhân dân. v. [1] + Hà
Nội, Quân Đội Nhân Dân, 1978 +
U54.V53A56 Orien Viet
80-984099**

The Hero of the People's Armed Forces. V. 1, (Hanoi: The People's Army, 1978)

Library of Congress Subject Heading : U [Military Science]

Topics 1982 and 1987

#	Weight	Topic tokens	General Topic
20	0.06321	truyện tập ngắn ngày người vui dái bạn biển cơn gọi nơi sâu ngán thơ_ca chân_trời cửa thư non cà mau Story, volume, short, poem, song, horizon	Textual format, story, genre
5	0.06214	tập thơ nước truyện_ký sáng trong hoa đất truyện_ngắn núi lửa đất rừng lửa giữa nhiều tác_giả thơ_văn đất mặt Volume, poem, country, memoir, short story, mountain, jungle, author, verse	Poetry, nature, memoir, author
96	0.06051	trong của mới một những cách_mạng năm văn_hóa đèn nội văn_nghệ giai_đoạn dân_tộc nhiệm_vụ hoạch văn đầu liên đèn dòng_sông Revolution, literature, performance, stage, nation, action, function, channel	Revolution, action
22	0.05975	bán thứ lần lần truyện_dài tái của xuất lần bản đời xuất xuất khanh xuất hoang lần tựa phụ hậu Number, times, long story, published	Textual format, republished, genre
78	0.05733	nam việt miền tại cộng_sản phong_trào bắc phụ_nữ công_đoàn câu nửa tiếng chương hiện_đại khoa_học_xã_hội tra chủ thám lập tiếng South, Viet, region, Communism, movement, north, women, union, modern, social sciences	Communism, region, women, social sciences
31	0.0571	thứ lần lần bổ_sung sửa_chữa hành tái_bản đại_hội tên một huân bắc bơi đẹp trang vàng pic quảng lửa thức Number, supplement, repair, reprint, meeting, north	Number, reprint
7	0.05663	văn nguyên của phạm ngọc giới_thiệu dương hồng nguyên đình xuân đức văn chú tường hữu lâm bụi ngữ biên Literature, introduction, language	Literature, language
65	0.05164	thuyết tiểu thuyết thuyết tiểu người gián_điệp thuyết rừng lịch_sử thuybt tiểu tiêu xanh bảo vàng trẻ phò hận Novel, fiction, spy, forest, history	Novel, spy, history
97	0.04697	minh chí chi thành đồng pho truyện_ký trường_ca thông phò lăng ca_dao thành đạo tiền lộc tiền cao triều phường Memoir, epic, poem	Memoir, epics
24	0.04633	của người những bác anh làm thanh_niên trẻ điều phần giống nghĩ tuổi sủng tám cảm trẻ như giờ bất Youth, young, think, age, time	Youth

Hanoi v. Saigon

1982

#	General Topic	Hanoi	Saigon
5	Poetry, nature, memoir, author	0.009808929	0.008638799
96	Revolution, action	0.030214885	0.021528166
78	Communism, region, women, social sciences	0.008836326	0.008266742

- From 1982 to 1987 decrease in topics Communism 96 and 78 for Saigon.

- In 1987 topic 96 difference in Hanoi and Saigon

1987

#	General Topic	Hanoi	Saigon
5	Poetry, nature, memoir, author	0.011779472	0.009184172
96	Revolution, action	0.034526805	0.013463745
78	Communism, region, women, social sciences	0.004967198	0.007170078

Results

1. Different publication locations will have different distribution of topics.
What are the topics/words most characteristic of a city?
 - a. H1: Hanoi will have more topics on Communism, war, revolution, army than Saigon.
 - i. → Naive bayes suggest this is true.
 - ii. → Topic models suggests* cN
 - b. H2: Saigon will have more topics on US ideas (modernity, democracy, anti-Communism)
 - i. → Naive bayes suggests other topics such as Buddhism, homeland
 - ii. → Topic models suggests * CN
 - c. H3: LOC collection will prefer Saigon (ally) materials over Hanoi.
 - i. Frequency counts demonstrate preference over Hanoi than Saigon.

Concluding Remarks

- Challenges of data cleaning/OCR
- Confounding factor of **collection policy of LOC v. universe of published materials in Vietnam**
- Value of quantitative analysis for history discipline

Concluding Remarks

1. Power of counting
2. Power of probability

Future Directions

Feature	β
Published in Hanoi	
Published in Saigon	
Topic 44 “Revolution, worker”	
Topic 51 “Saigon, home”	
Topic 5 “War poetry”	
$P(X = \text{“Hero”} Y = \text{Hanoi}) = .0005298$	


Classification:

- Was this published in Hanoi? Saigon?
- Was this text pro-Communist or anti-Communist?

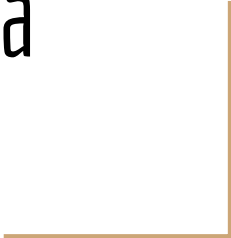
Research:

- What types of works were published in Saigon? Hanoi?
- What types of works were collected by the LOC?

Possible Ways to Featurize Data



Reading by Machines: Open Refine on OCR Output Data



Cindy A. Nguyen, History
University of California, Berkeley

Data Cleaning

DATA

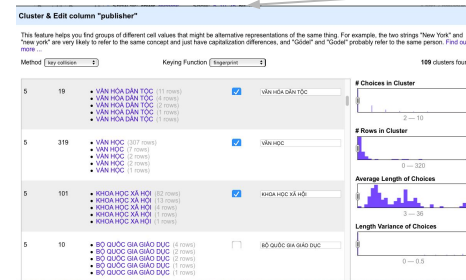
- Data cleaning and preparation:

- **Optical Character Recognition** (Abbyy Finereader): from PDF to text file
- **Regex**: extract author, title, year, publisher, location
- **Google Refine**: clean up data fields, resolve OCR errors and misspellings
- **vnTokenizer**: tokenize Vietnamese words cách mạng = cách-mạng [revolution]

13
35 năm chiến đấu và xây dựng. Hà Nội, Sự Thật, 1980.
DS556.8.A13 1980 Orien Viet
83-189533
426 p. illus., plates.
Includes bibliographical references.

14
Ba ngày lễ lớn năm 1980; để cương tuyến truyền. Hà
Nội, Quân Đội Nhân Dân, 1980.
DS559.912.B3 Orien Viet
81-203188
129 p.

```
13
35 năm chiến đấu và xây dựng. Hà Nội, Sự Thật, 1980.
DS556.8.A13 1980 Orien Viet
83- 189533
426 p. illus., plates.
Includes bibliographical references.
14
Ba ngày lễ lớn năm 1980; để cương tuyến truyền. Hà
Nội, Quân Đội Nhân Dân, 1980.
DS559.912.B3 Orien Viet
81- 203188
129 p.
```



35 years of war and building

3 major holidays in 1980; an outline of the stories of beloved uncle Hồ

35 năm chiến đấu và xây dựng
ba ngày lễ lớn năm 1980 ; để cương tuyến truyền
bác hồ kính yêu

Open Refine

OpenRefine (formerly Google Refine) is an open powerful tool for working with messy data: cleaning it; transforming it from one format into another; and extending it with web services and external data.

Why?

Exploring, finding, fixing inconsistencies due to typos and OCR output

Undo/Redo (track changes): freedom to make mistakes

Tutorial Resources

Programming Historian

<http://programminghistorian.org/lessons/cleaning-data-with-openrefine>

Videos & Community Board (Install Google Refine 2.5 - Stable)

<http://openrefine.org>

Digital Humanities & Open Refine (Today's walkthrough)

<http://thomaspadilla.org/dataprep/>

Data

<https://github.com/cindyanguyen/tutorial-data>

Favorite Operations

1. Text Facet/Numeric Facet: Locating inconsistencies in OCR, typos (sort by count/name)
2. Clustering: Helpful with diacritical errors in Vietnamese
3. Google Refine Expression Language(GREL): `value.replace('||', '|')`
 - a. <https://github.com/OpenRefine/OpenRefine/wiki/GREL-Functions>
4. Common error: multiple facets/filters layered

First Steps:

1. Remove trailing whitespace
2. Capitalization: all lower case

Resources

Open Refine Lessons for Digital Humanities

<https://data-lessons.github.io/dh-openrefine/>

Tidy Data by Hadley Wickham - Datasets easy to manipulate, model, visualize, have specific structure: each variable is a column, each observation is a row, and each type of observational unit is a table.

<https://vita.had.co.nz/papers/tidy-data.pdf>

Digital Humanities x Data Science Short Reading List

<https://cindyanguyen.com/2016/04/09/digital-humanities-data-science-list/>